

UNIVERSITÉ CHOUAIB DOUKKALI
École Nationale des Sciences Appliquées – El Jadida
Département de Génie Informatique
Master en Sciences des Données et Intelligence Artificielle (SDIA)

RAPPORT DE MINI PROJET

Module : Deep Learning

**Système de Détection d’Intrusion
Basé sur l’Intelligence Artificielle**

*Une Étude Comparative sur NSL-KDD et CSE-CIC-IDS2018 :
Apprentissage Automatique Classique, Apprentissage Profond (CNN, BiLSTM, MLP),
et Architectures d’Ensemble Hybrides*

Réalisé par :

EL MAHDI BOUDERNA
Yassine Mounabih
Yassine EL Hattab

Encadré par :

Prof. Youness Abouqora

Année Universitaire : 2025 – 2026

TABLE DES MATIÈRES

Table des figures	iii
Liste des tableaux	iv
Liste des Acronymes	v
Introduction Générale	1
1 État de l’Art	2
1.1 Paradigmes de Détection	2
1.2 Apprentissage Automatique Classique pour les IDS	2
1.3 Architectures d’Apprentissage Profond pour les IDS	2
1.4 Ensembles Hybrides et Jeux de Données de Référence	3
2 Jeux de Données et Prétraitement	4
2.1 Jeu de Données NSL-KDD	4
2.2 Jeu de Données CSE-CIC-IDS2018	5
3 Expériences d’Apprentissage Automatique Classique	7
3.1 Modèles et Configurations	7
3.2 Résultats sur NSL-KDD	7
3.3 Résultats sur CSE-CIC-IDS2018	9
4 Apprentissage Profond et Architectures Hybrides	11
4.1 NSL-KDD — Résultats de l’Apprentissage Profond	11
4.1.1 LSTM / RNN	11
4.1.2 CNN 1D	11
4.1.3 XGBoost Seul (Référence)	11
4.2 CSE-CIC-IDS2018 — Résultats de l’Apprentissage Profond	11
4.2.1 CNN 1D (Ajusté avec Keras Tuner)	11
4.2.2 LSTM Bidirectionnel	12

4.2.3	Perceptron Multicouche (MLP)	13
4.3	Architectures d'Ensemble Hybrides	13
4.3.1	Hybride NSL-KDD 1 : XGBoost + CNN (Filtre en Cascade)	13
4.3.2	Hybride NSL-KDD 2 : XGBoost + RF + MLP (Vote Souple Pondéré)	13
4.3.3	Hybride CSE-CIC-IDS2018 1 : XGBoost + CNN (Empilement de Caractéristiques)	15
4.3.4	Hybride CSE-CIC-IDS2018 2 : XGBoost + RF + MLP (Ensemble d'Empilement)	15
4.4	Analyse Comparative	15
5	General Conclusion	17
5.1	Principal Findings	17
5.2	Perspectives and Future Work	17

TABLE DES FIGURES

2.1	Distribution des types d'attaques dans l'ensemble d'apprentissage de NSL-KDD	4
2.2	Distribution des échantillons par classe dans le jeu de données CSE-CIC-IDS2018	6
3.1	Précision et scores F1 des modèles classiques sur NSL-KDD	8
3.2	Matrice de confusion du classificateur Gradient Boosting sur NSL-KDD . .	9
3.3	Matrices de confusion des modèles classiques : de base (en haut) vs. ajustés (en bas)	10
4.1	Matrice de confusion — CNN 1D sur CSE-CIC-IDS2018	12
4.2	Courbe de compromis FP/FN pour l'ensemble NSL-KDD à travers les seuils de décision	14
4.3	Matrice de confusion — Ensemble XGB+RF+MLP sur NSL-KDD ($\tau = 0,25$)	14
4.4	Comparaison de la précision finale des modèles sur CSE-CIC-IDS2018 . .	16
4.5	Comparaison de la précision inter-jeux de données : NSL-KDD vs. CSE-CIC-IDS2018	16

LISTE DES TABLEAUX

2.1	Composition du jeu de données NSL-KDD	4
2.2	Distribution du trafic dans CSE-CIC-IDS2018	5
3.1	Configurations des modèles d'apprentissage automatique classique pour NSL-KDD	7
3.2	Configurations des modèles d'ensemble pour CSE-CIC-IDS2018	7
3.3	Résultats de l'apprentissage automatique classique sur KDDTest+ (classification binaire)	8
3.4	Modèles classiques : de base vs. ajustés sur CSE-CIC-IDS2018	9
4.1	CSE-CIC-IDS2018 — Résultats par classe du CNN 1D (ensemble de test, 149 980 échantillons)	12
4.2	Comparaison des modèles de réseaux de neurones sur CSE-CIC-IDS2018 .	13
4.3	Compromis FP/FN selon les seuils de décision τ (Ensemble hybride NSL-KDD)	14
4.4	Comparaison des modèles hybrides sur CSE-CIC-IDS2018	15
4.5	Résumé complet des performances à travers tous les modèles et jeux de données	15

LISTE DES ACRONYMES

AI	Artificial Intelligence
AUC	Area Under the (ROC) Curve
BiLSTM	Bidirectional Long Short-Term Memory
CIC	Canadian Institute for Cybersecurity
CNN	Convolutional Neural Network
DDoS	Distributed Denial of Service
DL	Deep Learning
DoS	Denial of Service
F1	F1-Score (harmonic mean of Precision and Recall)
FN	False Negative
FP	False Positive
IDS	Intrusion Detection System
KDD	Knowledge Discovery and Data Mining
KNN	K-Nearest Neighbours
LightGBM	Light Gradient Boosting Machine
LSTM	Long Short-Term Memory
ML	Machine Learning
MLP	Multilayer Perceptron
NIDS	Network Intrusion Detection System
NSL-KDD	Network Security Laboratory – Knowledge Discovery and Data Mining dataset
PFA	Projet de Fin d’Année (Final Year Project)
RF	Random Forest
RNN	Recurrent Neural Network
ROC	Receiver Operating Characteristic
SDIA	Science des Données et Intelligence Artificielle (Data Science and Artificial Intelligence)
SHAP	SHapley Additive exPlanations
SMOTE	Synthetic Minority Over-sampling Technique
SVM	Support Vector Machine
XGBoost	eXtreme Gradient Boosting

INTRODUCTION GÉNÉRALE

La transformation numérique des sociétés modernes a fondamentalement modifié le paysage des menaces pesant sur la sécurité de l'information. Les secteurs des infrastructures critiques, des systèmes financiers à la santé, s'appuient sur des environnements en réseau exposés à des activités adverses sophistiquées, notamment les menaces persistantes avancées (APT), les failles zero-day, les campagnes de déni de service distribué (DDoS) et l'exfiltration furtive de données.

Les **Systèmes de Détection d'Intrusion (IDS)** représentent une ligne de défense indispensable. Les approches basées sur les signatures sont fondamentalement réactives (incapables d'identifier les nouvelles menaces), ce qui oriente la recherche vers la détection d'anomalies à l'aide de l'apprentissage automatique. Le domaine est passé des méthodes d'ensemble classiques aux architectures d'apprentissage profond capables de capturer des interactions complexes de caractéristiques, facilitées par des benchmarks réalistes à grande échelle tels que CSE-CIC-IDS2018 [2].

Ce projet de fin d'année, réalisé au sein du Master SDIA de l'ENSA El Jadida, poursuit les objectifs suivants :

- Évaluer huit algorithmes classiques d'apprentissage automatique pour la détection d'intrusion binaire sur NSL-KDD ;
- Implémenter et évaluer trois architectures d'apprentissage profond (BiLSTM, CNN 1D, MLP) sur les deux jeux de données ;
- Étendre l'évaluation à CSE-CIC-IDS2018, un problème à dix classes avec plus d'un million d'échantillons ;
- Concevoir et évaluer deux architectures d'ensemble hybrides par jeu de données ;
- Analyser l'impact du déséquilibre des classes et l'effet de l'étalonnage du seuil de décision.

Le rapport est organisé comme suit. Le chapitre 1 passe en revue l'état de l'art. Le chapitre 2 décrit les deux jeux de données et leur prétraitement. Le chapitre 3 couvre les résultats de l'apprentissage automatique classique. Le chapitre 4 couvre l'apprentissage profond, les architectures hybrides et une analyse comparative exhaustive de tous les modèles. Le chapitre 5 conclut avec les principales découvertes et les perspectives d'avenir.

CHAPITRE 1

ÉTAT DE L'ART

1.1 Paradigmes de Détection

Un système de détection d'intrusion réseau (NIDS) distingue globalement deux paradigmes. **La détection par signature** confronte les événements à des modèles d'attaques connus—très précis pour les menaces cataloguées mais inefficaces contre les attaques zero-day. **La détection par anomalie** construit un modèle de comportement normal et signale les déviations ; bien que capable de détecter de nouvelles attaques, elle génère des taux de faux positifs plus élevés. Les architectures IDS hybrides combinent les deux, utilisant la correspondance de signatures comme premier filtre et la détection d'anomalies pour le trafic résiduel.

1.2 Apprentissage Automatique Classique pour les IDS

Les méthodes d'ensemble basées sur les arbres dominent la littérature des IDS pour les données réseau tabulaires. Les **Forêts Aléatoires (Random Forests)** réduisent la variance grâce à l'agrégation bootstrap. Les **Machines d'Amplification de Gradient (Gradient Boosting Machines)** corrigent itérativement les erreurs résiduelles, excellant sur les modèles d'attaques subtils. **XGBoost** et **LightGBM** accélèrent l'amplification de gradient avec une construction d'arbres basée sur des histogrammes. Des études antérieures ont révélé que RF et XGBoost apparaissent dans plus de 60 % des systèmes IDS les plus performants. Les SVM restent compétitifs sur des jeux de données de taille modérée mais sont prohibitivement lents sur des données de l'ordre du million d'enregistrements en raison d'une complexité de $O(n^2)$ – $O(n^3)$.

1.3 Architectures d'Apprentissage Profond pour les IDS

Les **CNN 1D**, conçus à l'origine pour la reconnaissance d'images, ont démontré une extraction robuste de caractéristiques à partir de flux réseau tabulaires en traitant le vecteur de caractéristiques comme un signal 1D. Leur efficacité en termes de paramètres grâce au partage des poids permet une détection efficace des corrélations locales de caractéristiques.

Les **réseaux LSTM** sont théoriquement adaptés aux données séquentielles. Le LSTM bi-directionnel (BiLSTM) traite les séquences dans les deux sens pour un contexte plus riche. Cependant, lorsque les flux réseau sont représentés comme des *agrégats statistiques*—comme dans NSL-KDD et CSE-CIC-IDS2018—les LSTM ajoutent une charge de calcul sans avantage représentationnel par rapport aux CNN ou aux MLP.

Des modèles **basés sur les Transformers** ont récemment été appliqués aux IDS avec des plongements contextuels améliorant la détection de catégories d'attaques à faible fréquence, mais exigent beaucoup plus de ressources de calcul.

1.4 Ensembles Hybrides et Jeux de Données de Référence

Les ensembles hétérogènes surpassent systématiquement les classificateurs uniques : empiler XGBoost avec les sorties d'un réseau neuronal réduit à la fois les taux de faux positifs et de faux négatifs. Deux jeux de données occupent des positions centrales dans la littérature récente :

- **NSL-KDD** [1] : Corrige la redondance de KDD Cup 1999. Malgré son ancienneté, il reste le benchmark le plus utilisé en raison de sa petite taille et de ses propriétés bien comprises.
- **CSE-CIC-IDS2018** [2] : Généré par l'Institut Canadien pour la Cybersécurité (CIC) sur sept jours dans une topologie d'entreprise réaliste. Son ampleur (>16M d'enregistrements) et sa diversité le rendent plus représentatif que les anciens benchmarks.

La littérature souligne systématiquement trois défis : **le déséquilibre des classes** (traité par la pondération des classes, SMOTE et l'étalonnage des seuils); **la généralisation** à travers les environnements réseau; et **l'interprétabilité** via les outils d'IA explicable (XAI) comme SHAP et LIME.

CHAPITRE 2

JEUX DE DONNÉES ET PRÉTRAITEMENT

2.1 Jeu de Données NSL-KDD

Introduit par Tavallae et al. en 2009 [1], NSL-KDD remédie à deux lacunes de KDD Cup 1999 : la suppression des doublons et la sélection des enregistrements stratifiée par difficulté. Chaque enregistrement décrit une connexion TCP/IP avec **41 caractéristiques** (propriétés de la connexion, caractéristiques de contenu dérivées de la charge utile et statistiques de trafic temporelles), étiquetée comme normale ou l'un des 39 sous-types d'attaques regroupés en quatre familles (DoS, Probe, R2L, U2R). La composition du jeu de données et la distribution des classes sont présentées dans le Tableau 2.1 et la Figure 2.1.

TABLE 2.1 – Composition du jeu de données NSL-KDD

Sous-ensemble	Enregistrements	Normal	Attaques
KDDTrain+	125,973	67,343 (53,5%)	58,630 (46,5%)
KDDTest+	22,544	9,711 (43,1%)	12,833 (56,9%)




FIGURE 2.1 – Distribution des types d'attaques dans l'ensemble d'apprentissage de NSL-KDD

Pipeline de prétraitement : Tous les sous-types d'attaques sont mappés vers une seule classe

d'attaque (binaire). La colonne `difficulty` est supprimée pour éviter toute fuite de données. Les caractéristiques catégorielles (`protocol_type`, `service`, `flag`) sont encodées par labels pour les modèles basés sur les arbres et avec l'encodage one-hot pour les modèles d'apprentissage profond, étendant le vecteur à ≈ 122 caractéristiques. Toutes les caractéristiques numériques sont standardisées (moyenne nulle, variance unitaire) à l'aide d'un scaler ajusté exclusivement sur les données d'entraînement. Pour l'apprentissage profond, les entrées sont remodelées en $(samples, features, 1)$ pour le CNN ou en $(samples, 1, features)$ pour le BiLSTM.

2.2 Jeu de Données CSE-CIC-IDS2018

Publié par l'Institut Canadien pour la Cybersécurité [2], ce jeu de données a été généré sur sept jours consécutifs dans un réseau d'entreprise contrôlé (50 machines attaquantes, 420 machines victimes). Les fichiers PCAP bruts ont été traités en **77 caractéristiques numériques de flux** via CICFlowMeter, couvrant la durée des flux, les temps d'inter-arrivée, les statistiques de longueur de paquet, le nombre d'indicateurs (flags) et les débits. Le jeu de données comprend 15 types d'attaques distincts répartis en six familles (Tableau 2.2).

TABLE 2.2 – Distribution du trafic dans CSE-CIC-IDS2018

Famille	Types d'Attaques	Volume
Benign	Trafic normal	5,329,008
DDoS	DDoS-LOIC-HTTP, DDOS-HOIC, DDOS-LOIC-UDP	775,955
DoS	DoS-Hulk, DoS-GoldenEye, DoS-Slowloris, DoS-SlowHTTPTest	196,568
Brute Force	SSH-Bruteforce, FTP-BruteForce, Brute Force-Web, Brute Force-XSS	94,898
Bot	Bot	144,535
Infiltration	Infiltration	118,483
Web Attacks	SQL Injection, Brute Force-XSS	85




FIGURE 2.2 – Distribution des échantillons par classe dans le jeu de données CSE-CIC-IDS2018

Pipeline de prétraitement : Le jeu de données est distribué sous forme de fichiers Parquet. Après la concaténation, la colonne `Timestamp` est supprimée et les valeurs infinies/NaN sont nettoyées. Les données sont sous-échantillonnées à 1 000 000 d’enregistrements pour faciliter le calcul. Cinq classes d’attaques avec moins de 100 échantillons post-sous-échantillonnage (SQL Injection, DoS-SlowHTTPTest, FTP-BruteForce, Brute Force-Web, Brute Force-XSS) sont supprimées, ce qui donne un problème à **10 classes**. Les données sont réparties 70/15/15 (entraînement/validation/test) avec un échantillonnage stratifié. La standardisation des caractéristiques suit la même approche (ajustement sur l’entraînement uniquement) que pour NSL-KDD. Les poids équilibrés des classes sont calculés comme $w_c = N/(K \cdot n_c)$, et plafonnés pour prévenir l’instabilité due aux classes très rares.

CHAPITRE 3

EXPÉRIENCES D'APPRENTISSAGE AUTOMATIQUE CLASSIQUE

3.1 Modèles et Configurations

Sur **NSL-KDD**, huit classificateurs supervisés ont été évalués pour la classification binaire (Tableau 3.1). Sur **CSE-CIC-IDS2018**, trois méthodes d'ensemble extensibles (Forêt Aléatoire, XGBoost, LightGBM) ont été évaluées dans des configurations de base et avec réglage d'hyperparamètres sur un sous-échantillon de 300 000 enregistrements (Tableau 3.2).

TABLE 3.1 – Configurations des modèles d'apprentissage automatique classique pour NSL-KDD

Modèle	Paramètres Clés
Random Forest	n_estimators=100
Decision Tree	Critère de Gini, profondeur non restreinte
SVM	Noyau RBF, $C = 1$
KNN	$k = 5$, distance euclidienne
Logistic Regression	max_iter=2000, solveur lbfgs
Naive Bayes (Gaussian)	Distribution gaussienne par caractéristique
AdaBoost	n_estimators=100, taux d'apprentissage 1.0
Gradient Boosting	n_estimators=100, lr=0.1

TABLE 3.2 – Configurations des modèles d'ensemble pour CSE-CIC-IDS2018

Modèle	Base	Ajusté (Tuned)
Random Forest	n_est=200, depth=20	n_est=300, depth=25, balanced_subsample
XGBoost	n_est=500, depth=6, lr=0.05	Régularisation accrue ($\gamma = 2, \lambda = 3$)
LightGBM	n_est=500, depth=8, lr=0.05	n_est=1000, lr=0.03, min_child=20

3.2 Résultats sur NSL-KDD

Le Tableau 3.3 présente les métriques complètes pour les huit classificateurs. Gradient Boosting atteint la plus grande précision (**80,6 %**) et le meilleur score F1 (**0,800**), mais son rappel

de 0,682 signifie qu’il manque environ 32 % de toutes les attaques—un biais systématique de faux négatifs qui justifie les stratégies hybrides et d’étalonnage des seuils.

TABLE 3.3 – Résultats de l’apprentissage automatique classique sur KDDTest+ (classification binaire)

Modèle	Précision globale	Précision (Precision)	Rappel (Recall)	F1
Gradient Boosting	0,806	0,968	0,682	0,800
Decision Tree	0,792	0,963	0,623	0,756
AdaBoost	0,790	0,964	0,657	0,781
SVM (RBF)	0,782	0,976	0,633	0,768
Random Forest	0,781	0,965	0,607	0,745
Naive Bayes	0,771	0,911	0,663	0,768
KNN ($k=5$)	0,768	0,971	0,610	0,749
Logistic Regression	0,754	0,925	0,618	0,741




FIGURE 3.1 – Précision et scores F1 des modèles classiques sur NSL-KDD





FIGURE 3.2 – Matrice de confusion du classificateur Gradient Boosting sur NSL-KDD

3.3 Résultats sur CSE-CIC-IDS2018

L'ajustement des hyperparamètres apporte des améliorations substantielles (Tableau 3.4). La Forêt Aléatoire (Random Forest) ajustée atteint **94,80 %** de précision (+4,65 points de pourcentage). XGBoost bénéficie le plus de l'ajustement (+12,19 pp). La classe Infiltration reste un défi persistant pour tous les modèles ($F1 = 0,14\text{--}0,19$), en accord avec la littérature générale : ces attaques imitent le trafic normal et génèrent un minimum de déviations statistiques dans les caractéristiques de flux.

TABLE 3.4 – Modèles classiques : de base vs. ajustés sur CSE-CIC-IDS2018

Modèle	Précision (Base)	Précision (Ajustée)	Gain
Random Forest	90,15 %	94,80 %	+4,65 pp
XGBoost	79,44 %	91,63 %	+12,19 pp
LightGBM	83,60 %	84,86 %	+1,26 pp



CHAPITRE 4

APPRENTISSAGE PROFOND ET ARCHITECTURES HYBRIDES

Trois architectures de réseaux neuronaux ont été évaluées sur les deux jeux de données : LSTM Bidirectionnel (BiLSTM), CNN 1D et MLP. Toutes utilisent un entraînement pondéré par classe. Quatre stratégies hybrides (deux par jeu de données) combinent les forces complémentaires des modèles basés sur les arbres et des réseaux de neurones.

4.1 NSL-KDD — Résultats de l'Apprentissage Profond

4.1.1 LSTM / RNN

Un LSTM à deux couches (64 et 32 unités, dropout 0,3, sortie sigmoïde, entropie croisée binaire) atteint **79,9 %** de précision avec 3 980 faux négatifs—mieux que le CNN seul au seuil par défaut, mais en deçà du Gradient Boosting classique.

4.1.2 CNN 1D

Un CNN à deux blocs (Conv1D-64, MaxPool, Conv1D-32, MaxPool, Dense-64, Dropout-0,3, sigmoïde) atteint **78,1 %** au seuil par défaut de 0,5 avec 4 265 faux négatifs. L'ajout de poids explicites pour les classes et l'abaissement du seuil à 0,3 réduisent les FN à **3 831** (précision : 79,8 %).

4.1.3 XGBoost Seul (Référence)

XGBoost seul (400 estimateurs, profondeur 6, lr 0,05, seuil 0,3) atteint **81,1 %** avec seulement 277 faux positifs mais 3 972 faux négatifs, confirmant sa complémentarité avec le CNN : haute précision, moins de FP, mais des FN similaires.


4.2 CSE-CIC-IDS2018 — Résultats de l'Apprentissage Profond

4.2.1 CNN 1D (Ajusté avec Keras Tuner)

Le CNN 1D ajusté (deux blocs Conv1D avec BatchNormalization, GlobalAveragePooling, Dense-128, Dropout-0,3) atteint **97,98 %** de précision—la plus élevée de tous les modèles sur ce jeu de données (Tableau 4.1, Figure 4.1).

TABLE 4.1 – CSE-CIC-IDS2018 — Résultats par classe du CNN 1D (ensemble de test, 149 980 échantillons)

Classe	Précision	Rappel	F1	Support
Benign	0,98	1,00	0,99	119 996
Bot	1,00	0,99	0,99	3 273
DDoS attack-HOIC	0,99	1,00	1,00	4 507
DDoS attack-LOIC-UDP	0,75	0,97	0,84	39
DDoS attacks-LOIC-HTTP	0,99	1,00	1,00	12 929
DoS attacks-GoldenEye	0,99	1,00	1,00	925
DoS attacks-Hulk	0,99	1,00	0,99	3 284
DoS attacks-Slowloris	0,83	0,98	0,90	228
Infiltration	0,34	0,04	0,08	2 665
SSH-Bruteforce	1,00	1,00	1,00	2 134
Précision globale		97,98 %		
Moyenne macro	0,89	0,90	0,88	149 980

**FIGURE 4.1** – Matrice de confusion — CNN 1D sur CSE-CIC-IDS2018

4.2.2 LSTM Bidirectionnel

Le BiLSTM n'atteint que **67,17 %** de précision sur CSE-CIC-IDS2018—loin derrière tous les autres modèles. La précision de validation plafonne à 66–67 % tandis que la perte de validation diverge.

Pourquoi le BiLSTM sous-performe sur les données IDS au niveau des flux

Les caractéristiques de CSE-CIC-IDS2018 sont des *agrégats statistiques* calculés sur l'ensemble des flux. Elles ne comportent aucun ordre temporel entre les dimensions des caractéristiques. Les injecter comme une séquence dans un LSTM gaspille la capacité sur des dépendances inexistantes et ajoute ≈ 33 s/époque de temps d'entraînement contre 1 s/époque pour le MLP.

4.2.3 Perceptron Multicouche (MLP)

Le MLP (Dense-256, BatchNorm, Dropout-0,3, Dense-128, BatchNorm, Dropout-0,3, Dense-64, Dropout-0,2, Softmax) atteint **97,97 %** de précision—virtuellement identique au CNN, mais s'entraîne en ≈ 1 s/époque. Du point de vue du déploiement, le MLP est préféré : une précision équivalente pour une fraction du temps d'entraînement.

TABLE 4.2 – Comparaison des modèles de réseaux de neurones sur CSE-CIC-IDS2018

Modèle	Précision de Test	Vitesse d'Entraînement	Notes
CNN 1D	97,98 %	Moyenne	Le meilleur dans l'ensemble
MLP (DNN)	97,97 %	Rapide (≈ 1 s/ép.)	Presque identique au CNN
BiLSTM (RNN)	67,17 %	Lente (≈ 33 s/ép.)	Inéquation architecturale

4.3 Architectures d'Ensemble Hybrides

4.3.1 Hybride NSL-KDD 1 : XGBoost + CNN (Filtre en Cascade)



XGBoost (seuil 0,25) signale les attaques probables, qui sont ensuite validées par le CNN. Résultat : 81,1 % de précision, mais **4 069 FN**—*plus* que XGBoost seul (3 972 FN). La deuxième étape conservatrice du CNN dégrade le rappel, confirmant que le filtrage séquentiel est contre-productif lorsque l'objectif est de minimiser les attaques manquées.

4.3.2 Hybride NSL-KDD 2 : XGBoost + RF + MLP (Vote Souple Pondéré)

Le vote souple (soft voting) sur trois modèles étalonnés (poids XGBoost 3, poids RF 1, poids MLP 1) avec un seuil $\tau = 0,25$ atteint **90,2 %** de précision avec seulement **1 884 faux négatifs**—une amélioration spectaculaire par rapport à chaque modèle pris isolément. Un balayage systématique des seuils révèle le point de fonctionnement optimal à $\tau^* = 0,08$: **2 954 FN** (30,7 % de moins que le CNN par défaut), pour 347 faux positifs (Tableau 4.3, Figure 4.2).

TABLE 4.3 – Compromis FP/FN selon les seuils de décision τ (Ensemble hybride NSL-KDD)

Seuil τ	FP	FN	TP
0,01	460	1 871	10 962
0,05	367	2 525	10 308
0,08	347	2 954	9 879
0,10	334	3 066	9 767
0,25	302	3 607	9 226
0,30	292	3 732	9 101

**FIGURE 4.2** – Courbe de compromis FP/FN pour l'ensemble NSL-KDD à travers les seuils de décision**FIGURE 4.3** – Matrice de confusion — Ensemble XGB+RF+MLP sur NSL-KDD ($\tau = 0,25$)

4.3.3 Hybride CSE-CIC-IDS2018 1 : XGBoost + CNN (Empilement de Caractéristiques)

Les plongements de l'avant-dernière couche du CNN (128-dim) sont concaténés avec les vecteurs de probabilité de classe de XGBoost (10-dim) et transmis à une méta-tête. L'hybride atteint **97,89 %**—légèrement en dessous du CNN seul (97,98 %). L'entraînement s'achève en moins de deux minutes, ce qui en fait une alternative pratique.

4.3.4 Hybride CSE-CIC-IDS2018 2 : XGBoost + RF + MLP (Ensemble d'Empilement)

Les sorties de probabilité de classe de XGBoost, RF et MLP (30-dim combinés) alimentent une méta-tête plus profonde. Malgré la combinaison de trois modèles, la précision tombe à **96,43 %** : XGBoost et RF partagent des modèles d'erreur corrélés sur la classe Infiltration, et la méta-tête ne peut pas corriger les défaillances partagées systématiques.

TABLE 4.4 – Comparaison des modèles hybrides sur CSE-CIC-IDS2018

Hybride	Précision	Notes
XGB + CNN (stacking de caractéristiques)	97,89 %	Rapide (<2 min), perf. proche du CNN
XGB + RF + MLP (stacking)	96,43 %	Les erreurs corrélées limitent l'amélioration

4.4 Analyse Comparative

Le Tableau 4.5 consolide l'ensemble des résultats. Aucun modèle ne domine sur les deux jeux de données : l'ensemble XGB+RF+MLP est en tête sur NSL-KDD (90,2 %), tandis que le CNN autonome domine sur CSE-CIC-IDS2018 (97,98 %).

TABLE 4.5 – Résumé complet des performances à travers tous les modèles et jeux de données

Modèle / Approche	NSL-KDD	CIC-IDS2018	Notes
XGB+RF+MLP ($\tau=0,25$)	90,2 %	96,43 %	Meilleure précision NSL ; 1 884 FN
XGBoost (ajusté)	81,1 %	91,63 %	Moins de FP sur NSL (277)
XGB + CNN	81,1 %	97,89 %	Cascade (NSL) ; stacking (CIC)
Gradient Boosting	80,6 %	—	Meilleur F1 sur NSL (0,800)
BiLSTM / RNN	79,9 %	67,17 %	Inéquation architecturale sur CIC
CNN 1D (ajusté)	79,8 %	97,98 %	Meilleure précision CIC
Random Forest (ajusté)	78,1 %	94,80 %	Meilleur classique sur CIC
MLP / DNN	—	97,97 %	Quasi-égalité avec le CNN sur CIC
LightGBM (ajusté)	—	84,86 %	Score CIC ajusté le plus bas

À $\tau^*=0,08$, XGB+RF+MLP donne FN = 2 954 sur NSL-KDD (30,7 % de moins que le CNN par défaut).




FIGURE 4.4 – Comparaison de la précision finale des modèles sur CSE-CIC-IDS2018




FIGURE 4.5 – Comparaison de la précision inter-jeux de données : NSL-KDD vs. CSE-CIC-IDS2018

CHAPITRE 5

GENERAL CONCLUSION

5.1 Principal Findings

Dataset scale and feature richness drive performance. All model families improve systematically from NSL-KDD to CSE-CIC-IDS2018 : classical ensembles from 78–81% to 85–95%, deep learning from 78–80% to 97–98%. The richer 77-feature CICFlowMeter set and larger training volume explain this jump.

Accuracy alone is insufficient. On NSL-KDD, the XGB+RF+MLP ensemble at $\tau=0.25$ achieves 90.2% accuracy with only 1,884 FN—proving that architecture, calibration, and threshold together can improve both metrics simultaneously. Confusion matrices must always complement accuracy numbers.

Architectural fit matters more than complexity. The BiLSTM’s collapse to 67.17% on CIC is not a failure of deep learning (CNN and MLP achieve 97–98%). LSTM gating mechanisms require temporally ordered sequences, but flow features are statistical aggregates with no meaningful intra-vector ordering.

Class imbalance management is non-negotiable. Adding class weights and lowering the CNN threshold from 0.5 to 0.3 reduces false negatives from 4,265 to 3,831. The systematic threshold sweep on the ensemble reduces FN from 3,607 ($\tau=0.25$) to 2,954 ($\tau=0.08$)—an 18.1% further improvement.

Hybrid strategy matters more than hybrid count. The XGB+RF+MLP soft-voting ensemble outperforms the XGB+CNN cascade (1,884 vs. 4,069 FN) because the cascade degrades XGBoost’s recall. Adding more models without ensuring error diversity can worsen results.

The Infiltration problem remains open. Per-class recall for Infiltration is consistently 0.04–0.21 across all evaluated models ($F1 = 0.08$ – 0.17). These attacks deliberately mimic benign traffic, generating only minimal statistical deviations in flow-level features. Solving Infiltration detection likely requires longer time-window analysis or packet-level payload features beyond single-flow aggregates.

5.2 Perspectives and Future Work

Multi-class NSL-KDD. Extending NSL-KDD experiments to 5-class (Normal + DoS, Probe, R2L, U2R) with SMOTE or few-shot techniques for the rare R2L and U2R classes.

Attention mechanisms and transformers. TabTransformer and FT-Transformer have shown strong results on structured data ; their application to Infiltration detection merits exploration.

Online and continual learning. Static batch-trained models degrade as attack patterns evolve. Incremental learning frameworks that update parameters on incoming traffic are critical for operational deployment.

Generalisation across environments. Transfer learning and domain-adversarial training across IDS datasets from different network contexts could directly address the dataset bias problem.

Graph-based anomaly detection. Traffic has an inherent graph structure (hosts as nodes, flows as edges). Graph Neural Networks may capture structural attack patterns (e.g., port-scanning topologies) invisible to flow-level classifiers.

This study demonstrates that effective AI-based intrusion detection demands careful attention to dataset characteristics, preprocessing rigour, architectural suitability, and operational threshold design. The XGB+RF+MLP ensemble and the 1D CNN are the best practical choices for binary and multi-class IDS deployments respectively. The Infiltration challenge points toward richer feature representations and more advanced architectures as productive future directions.

BIBLIOGRAPHIE

- [1] M. Tavallaei, E. Bagheri, W. Lu, A. A. Ghorbani, *A Detailed Analysis of the KDD CUP 99 Data Set*, in *Proc. IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA)*, 2009, pp. 1–6.
- [2] I. Sharafaldin, A. H. Lashkari, A. A. Ghorbani, *Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization*, in *Proc. 4th International Conference on Information Systems Security and Privacy (ICISSP)*, 2018, pp. 108–116.
- [3] I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*, MIT Press, Cambridge, MA, 2016.
- [4] F. Pedregosa *et al.*, *Scikit-learn : Machine Learning in Python*, *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [5] M. Abadi *et al.*, *TensorFlow : A System for Large-Scale Machine Learning*, in *Proc. 12th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*, 2016, pp. 265–283.